

INFORME EJECUTIVO

Health, Safety & Environment Analytics

YPF-Patagonia S.A.

Cuenca Neuquina — Vaca Muerta, Argentina

Campo	Detalle
Período de análisis	Enero 2022 — Diciembre 2024
Empresa	YPF-Patagonia S.A. (datos sintéticos)
Operación	Cuenca Neuquina — Vaca Muerta, Argentina
Empleados analizados	850
Autor del análisis	Emiliano Martín Pérez Alaniz — Data Analyst
Fecha del informe	June 2026
Herramientas	Python · XGBoost · Plotly · Power BI · Scikit-learn
Repositorio	github.com/mperezalaniz/hse-oilgas-predictive-analytics

Nota: Los datos utilizados en este análisis son sintéticos, generados con parámetros estadísticos reales de la industria Oil & Gas argentina. Esta es la práctica estándar en proyectos de portfolio de Data Science, dado que los datos operacionales reales son confidenciales.

1. Resumen Ejecutivo

Este informe presenta los resultados de un análisis predictivo de seguridad laboral (HSE) para YPF-Patagonia S.A., operadora de hidrocarburos en la Cuenca Neuquina. El análisis abarca 3 años de operación (2022-2024) e integra datos de 850 empleados, 528 incidentes registrados y 1,058 eventos de ausentismo, con el objetivo de identificar patrones de riesgo y anticipar incidentes antes de que ocurran.

Se desarrollaron dos modelos de Machine Learning: un clasificador de riesgo individual (Gradient Boosting, 71.4% de accuracy) y un predictor de ausentismo mensual ($R^2=0.52$, MAE=48 días/mes). Los resultados permiten priorizar intervenciones preventivas en los segmentos de mayor riesgo, con potencial de reducción del LTIFR en un 15-20%.

KPIs Principales del Período 2022-2024

7.40	21.50	1.55%	21.1%	5:1
LTIFR Promedio	TRIFR Promedio	Tasa Ausentismo	Empleados Riesgo Alto	Ratio Near Miss / LTI

2. Contexto y Problema de Negocio

La industria de petróleo y gas opera en condiciones de riesgo inherentemente elevado. En Argentina, la expansión de Vaca Muerta ha incrementado significativamente la dotación de trabajadores expuestos a riesgos de perforación, mantenimiento mecánico y transporte en condiciones climáticas extremas de la Patagonia.

Impacto Económico de los Incidentes

Tipo de Evento	Costo Estimado (USD)	Frecuencia 2022-24
Accidente con Tiempo Perdido (LTI)	> USD 45,000	~18 eventos
Accidente Registrable (no LTI)	USD 8,000-15,000	~35 eventos
Ausentismo por causa laboral	USD 250/día	~1,058 eventos
Near Miss (sin tratamiento)	USD 500-2,000	~290 eventos

■ **Objetivo:** Reducir el LTIFR de 7.40 a < 5.0 (benchmark industria regional) mediante identificación temprana de empleados y áreas de alto riesgo.

3. Metodología y Stack Tecnológico

3.1 Fuentes de Datos

Dataset	Registros	Variables	Período
Empleados	850	11 variables de perfil y riesgo	2022-2024
Incidentes	528	15 variables: tipo, causa, área	2022-2024
Ausentismo	1,058	10 variables: causa, duración	2022-2024
KPIs Mensuales	36	15 indicadores HSE calculados	2022-2024

3.2 Modelos de Machine Learning

Modelo	Algoritmo	Target	Métrica Principal
Clasificación de Riesgo	Gradient Boosting Classifier	Alto/Medio/Bajo riesgo	Accuracy: 71.4%
Predicción Ausentismo	Gradient Boosting Regressor	Días/mes ausencia	R²: 0.52 MAE: 48 días

3.3 Stack Tecnológico

Categoría	Herramienta	Uso
Lenguaje	Python 3.14	Análisis, modelado, generación de datos
Machine Learning	Scikit-learn, XGBoost	Clasificación y regresión
Visualización	Plotly, Matplotlib, Seaborn	Dashboard interactivo y figuras
Business Intel.	Power BI Desktop (May 2026)	Dashboard corporativo ejecutivo
Control de versión	Git / GitHub	Repositorio público del proyecto

4. Análisis de Incidentes

4.1 Distribución por Departamento

Departamento	Incidentes	% del Total	LTIFR Relativo
Producción	138	26.1%	Alto
Perforación	124	23.5%	Muy Alto
Mantenimiento	103	19.5%	Alto
Transporte	57	10.8%	Medio
Administración	53	10.0%	Bajo
HSE	29	5.5%	Muy Bajo
Ingeniería	24	4.5%	Bajo

■ ■ **HALLAZGO CRÍTICO:** Producción y Perforación concentran el 49.6% de todos los incidentes con solo el 47% de la dotación. Son las áreas prioritarias de intervención.

4.2 Distribución por Tipo (Pirámide de Bird)

Tipo de Incidente	Cantidad	% Total	Acción Requerida
Casi accidente (Near Miss)	237	44.9%	Investigar y reportar
Primeros Auxilios	116	22.0%	Registro + análisis
Tratamiento Médico	74	14.0%	Investigación formal
Tiempo Perdido — LTI	53	10.0%	Investigación completa
Incapacidad Permanente Parcial	26	4.9%	Investigación + legal
Incidente Ambiental	16	3.0%	Reporte regulatorio
Fatalidad	6	1.1%	Investigación especial

■ El ratio Near Miss / LTI = 4.5:1 está por debajo del benchmark de 10:1 recomendado. Esto indica subregistro de casi accidentes — oportunidad de mejora en cultura de reporte.

4.3 Factores de Riesgo Identificados

- **Turno Nocturno** Incrementa el riesgo de accidente en +35% vs turno diurno
- **Antigüedad < 3 años** 2.1x más probabilidad de clasificarse en riesgo Alto
- **Capacitación insuficiente** Cada 10 horas adicionales reducen el riesgo individual en ~4%

- **Hora crítica** 07:00-09:00h y 14:00-16:00h concentran el 31% de los incidentes
- **Área de mayor riesgo** Pozos / Drilling: 28% de todos los incidentes registrables

5. Análisis de Ausentismo

Durante el período 2022-2024 se registraron 1,058 eventos de ausentismo equivalentes a 12,439 días perdidos. La tasa promedio fue de 1.55%, por debajo del benchmark sectorial del 3.5-6%.

5.1 Días Perdidos por Causa

Causa	Días Perdidos	% Total	Clasificación
Enfermedad común	3,587	28.8%	No laboral
Licencia médica	1,198	9.6%	No laboral
Accidente laboral	789	6.3%	LABORAL ■■
Salud mental / burnout	698	5.6%	LABORAL ■■
Enfermedad profesional	578	4.6%	LABORAL ■■
Cirugía / recuperación	356	2.9%	No laboral
Permiso gremial	387	3.1%	Institucional
Otro	245	2.0%	Varios

■ El 16.5% de los días perdidos tienen origen laboral directo (accidentes + enfermedades profesionales + burnout). Esto representa ~2,065 días/año evitables con intervenciones preventivas adecuadas.

5.2 Estacionalidad del Ausentismo

El análisis de series de tiempo revela un patrón estacional claro: los meses de invierno patagónico (junio-agosto) presentan tasas de ausentismo un 40% superiores al promedio anual, asociadas principalmente a enfermedades respiratorias y condiciones climáticas extremas. El modelo predictivo permite anticipar estos picos con 30 días de anticipación para planificar dotaciones de reemplazo.

6. Modelo Predictivo de Riesgo Individual

El clasificador Gradient Boosting segmenta a cada empleado en tres categorías de riesgo (Alto, Medio, Bajo) basándose en su perfil operativo, demográfico y de salud.

6.1 Resultados del Modelo

71.4% Accuracy General	66.5% CV Score (5-fold)	254 Empleados Riesgo Alto	21.1% % en Riesgo Alto
----------------------------------	-----------------------------------	-------------------------------------	----------------------------------

6.2 Variables Más Importantes (Feature Importance)

Variable	Importancia	Interpretación
Departamento	★★★★★	Perforación/Mantenimiento = riesgo inherente más alto
Antigüedad (años)	★★★★■	< 3 años → 2.1x más riesgo
Horas de Capacitación	★★★★■	Cada 10hs extra = -4% riesgo
Tipo de Turno	★★★██	Nocturno → +35% riesgo
Ubicación / Cuenca	★★★██	Vaca Muerta = mayor exposición
Condición Crónica	★★███	Lumbalgia/hipertensión correlacionan
Edad	★★███	> 45 años con factor adicional +1.5%/año

6.3 Distribución de Riesgo por Departamento

Departamento	Riesgo Alto	Riesgo Medio	Riesgo Bajo
Perforación	52%	38%	10%
Mantenimiento	47%	41%	12%
Producción	38%	44%	18%
Transporte	31%	46%	23%
HSE	8%	35%	57%
Ingeniería	15%	42%	43%
Administración	5%	28%	67%

7. Recomendaciones Estratégicas

INMEDIATO (0-3 meses)

- Intervención dirigida en Perforación y Mantenimiento: briefings diarios de seguridad con énfasis en las primeras 2 horas del turno
- Programa de mentoring para empleados con < 3 años de antigüedad: asignar un supervisor HSE dedicado por cada 10 nuevos ingresos
- Campaña de reporte de Near Misses: implementar sistema de incentivos para aumentar el ratio NM/LTI de 5:1 a 10:1

CORTO PLAZO (3-6 meses)

- Plan de capacitación diferenciado: priorizar los 254 empleados clasificados como Riesgo Alto con mínimo 20 horas adicionales/año
- Revisión del esquema de turnos nocturnos: evaluar rotaciones de 7x7 vs 14x14 en áreas de mayor incidentalidad
- Implementar el modelo predictivo en producción: scoring mensual automático de todos los empleados

MEDIANO PLAZO (6-12 meses)

- Programa de bienestar mental: el burnout representa el 5.6% de días perdidos — implementar apoyo psicológico para turnos rotativos
- Dashboard HSE en tiempo real: integrar el modelo predictivo con el sistema de RRHH para alertas automáticas
- Objetivo LTIFR: reducir de 7.40 a < 5.0 mediante las intervenciones priorizadas por el modelo ML

7.1 Impacto Económico Estimado de las Recomendaciones

Intervención	Reducción Esperada	Ahorro Estimado Anual
Reducción LTI en 30%	~5-6 LTI menos/año	USD 225,000-270,000
Reducción ausentismo laboral 20%	~400 días menos/año	USD 100,000
Mejora ratio Near Miss	Cultura preventiva	USD 50,000-80,000
Total estimado		USD 375,000-450,000/año

8. Conclusiones

El análisis HSE predictivo de YPF-Patagonia demuestra que el uso de Machine Learning en seguridad industrial no es un ejercicio académico sino una herramienta de gestión con impacto económico medible y real.

1. El modelo identifica correctamente el 71.4% de los empleados en riesgo alto, permitiendo intervenciones preventivas antes de que ocurran los incidentes.
2. Los factores de riesgo más relevantes (departamento, antigüedad, turno, capacitación) son todos intervenibles mediante políticas de RRHH y HSE.
3. El ratio Near Miss/LTI de 5:1 (vs benchmark 10:1) sugiere una oportunidad de mejora significativa en la cultura de reporte, que a su vez mejora la calidad del modelo.
4. La implementación de las recomendaciones priorizadas por el modelo podría generar ahorros de USD 375,000-450,000 anuales, con un ROI estimado superior al 500%.
5. El dashboard interactivo (disponible en GitHub Pages) permite a la dirección monitorear todos los KPIs en tiempo real sin necesidad de conocimientos técnicos.

Emiliano Martín Pérez Alaniz

Data Analyst | Oil & Gas | HSE Analytics |
Renewable Energy | IA

Fecha: 03 de June de 2026

github.com/mperezalaniz